

CUSTOMER CHURN PREDICTION

IMPORT DATA

Dataset *customer churn* berisi 4250 sampel dan setiap sampel berisi 19 variabel dengan 1 variabel target.

```
df_train.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 4250 entries, 0 to 4249
Data columns (total 20 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   state                                4250 non-null   object
1   account_length                       4250 non-null   int64
2   area_code                            4250 non-null   object
3   international_plan                   4250 non-null   object
4   voice_mail_plan                     4250 non-null   object
5   number_vmail_messages               4250 non-null   int64
6   total_day_minutes                   4250 non-null   float64
7   total_day_calls                     4250 non-null   int64
8   total_day_charge                     4250 non-null   float64
9   total_eve_minutes                   4250 non-null   float64
10  total_eve_calls                     4250 non-null   int64
11  total_eve_charge                     4250 non-null   float64
12  total_night_minutes                 4250 non-null   float64
13  total_night_calls                   4250 non-null   int64
14  total_night_charge                  4250 non-null   float64
15  total_intl_minutes                  4250 non-null   float64
16  total_intl_calls                     4250 non-null   int64
17  total_intl_charge                     4250 non-null   float64
18  number_customer_service_calls       4250 non-null   int64
19  churn                               4250 non-null   object
dtypes: float64(8), int64(7), object(5)
memory usage: 664.2+ KB
```

Melakukan import data *training* dan data *testing* ke dalam *workspace* dan menampilkan bentuk dari *dataset* tersebut.

Data Training

	state	account_length	area_code	international_plan	voice_mail_plan	number_vmail_messages	total_day_minutes	total_day_calls	total_day_charge	total
0	OH	107	area_code_415	no	yes	26	161.6	123	27.47	
1	NJ	137	area_code_415	no	no	0	243.4	114	41.38	
2	OH	84	area_code_408	yes	no	0	299.4	71	50.90	
3	OK	75	area_code_415	yes	no	0	166.7	113	28.34	
4	MA	121	area_code_510	no	yes	24	218.2	88	37.09	
...
4245	MT	83	area_code_415	no	no	0	188.3	70	32.01	
4246	WV	73	area_code_408	no	no	0	177.9	89	30.24	
4247	NC	75	area_code_408	no	no	0	170.7	101	29.02	
4248	HI	50	area_code_408	no	yes	40	235.7	127	40.07	
4249	VT	86	area_code_415	no	yes	34	129.4	102	22.00	

4250 rows x 20 columns

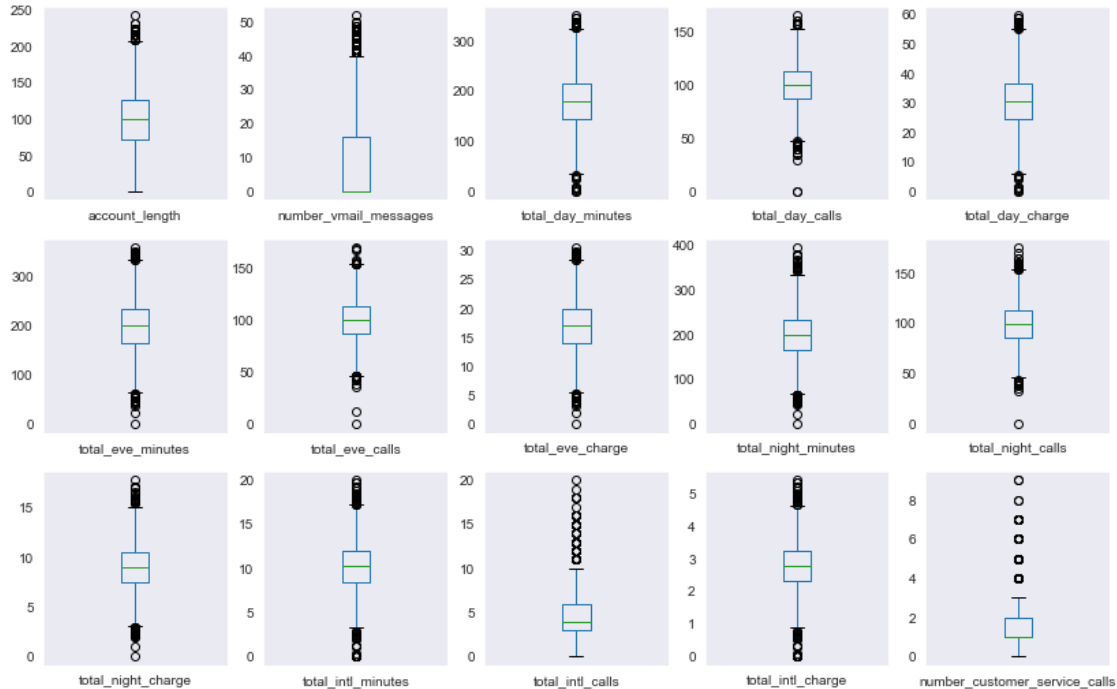
Data Testing

	id	state	account_length	area_code	international_plan	voice_mail_plan	number_vmail_messages	total_day_minutes	total_day_calls	total_day_charge
0	1	KS	128	area_code_415	no	yes	25	265.1	110	45.07
1	2	AL	118	area_code_510	yes	no	0	223.4	98	37.98
2	3	IA	62	area_code_415	no	no	0	120.7	70	20.52
3	4	VT	93	area_code_510	no	no	0	190.7	114	32.42
4	5	NE	174	area_code_415	no	no	0	124.3	76	21.13
...
746	746	GA	130	area_code_415	no	no	0	119.4	99	20.30
746	747	WA	73	area_code_408	no	no	0	177.2	118	30.12
747	748	WV	152	area_code_415	no	no	0	184.2	90	31.31
748	749	DC	61	area_code_415	no	no	0	140.6	89	23.90
749	750	DC	109	area_code_510	no	no	0	188.8	67	32.10

750 rows x 20 columns

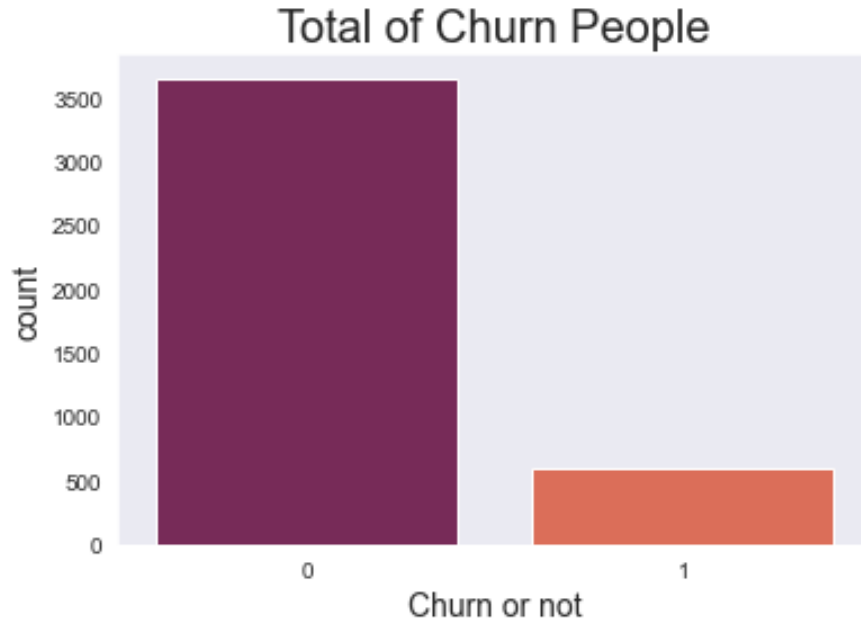
EXPLANATORY DATA ANALYSIS

- Deteksi dan Visualisasi Outliers**



EXPLANATORY DATA ANALYSIS

- **Target Variable : Churn**



Dapat dilihat bahwa dataset terindikasi memiliki ketidakseimbangan karena jumlah tidak *churn* lebih banyak daripada jumlah *churn*.


DATA PREPROCESSING

- Melakukan pengecekan *missing value*, tidak terdapat *missing value*.
- Menghapus kolom dari data 'state' dan 'area_code' karena tidak diikutsertakan dalam pemodelan.
- Mengubah tipe data yang masih berbentuk kategorik dalam bentuk numerik, yaitu data 'voice_mail_plan' dan 'international_plan'.
- Melakukan korelasi data.
- Melakukan *scaling* data dengan *Min-max Scaler*.

```
account_length      0
international_plan  0
voice_mail_plan     0
number_vmail_messages 0
total_day_minutes   0
total_day_calls     0
total_day_charge     0
total_eve_minutes   0
total_eve_calls     0
total_eve_charge     0
total_night_minutes 0
total_night_calls   0
total_night_charge   0
total_intl_minutes   0
total_intl_calls     0
total_intl_charge    0
number_customer_service_calls 0
churn               0
dtype: int64
```

```
ports={"no":0,"yes":1}
df_train['voice_mail_plan']=df_train['voice_mail_plan'].map(ports)
df_train['international_plan']=df_train['international_plan'].map(ports)
df_train
```

	account_length	international_plan	voice_mail_plan	number_vmail_messages
0	107	0	1	26
1	137	0	0	0
2	84	1	0	0
3	75	1	0	0
4	121	0	1	24
...
4245	83	0	0	0



MODELLING

Tahap 1 – Pembuatan Model

1. K-Nearest Neighbor (KNN)
2. Decision Tree
3. Random Forest

Tahap 2 – Meningkatkan Performa Model

1. Mencari model terbaik dengan *Randomized Search CV*
2. Mencari parameter terbaik dengan *Grid Search CV*

MODELLING RESULT

Tahap 1 – Pembuatan Model

Classifier	Accuracy	Precision	Recall
K-Nearest Neighbor (KNN)	90%	75%	40%
Decision Tree	92%	71%	72%
Random Forest	96%	97%	75%

Pada tahap ini, model yang direkomendasikan adalah *Random Forest* dengan *accuracy* : 0.90, *precision* : 0.97, dan *recall* : 0.75.

KNN:92.31					
	precision	recall	f1-score	support	
0	0.92	0.98	0.95	925	
1	0.75	0.40	0.52	138	
accuracy			0.90	1063	
macro avg	0.83	0.69	0.73	1063	
weighted avg	0.90	0.90	0.89	1063	
DT:100.0					
	precision	recall	f1-score	support	
0	0.96	0.96	0.96	925	
1	0.71	0.72	0.71	138	
accuracy			0.92	1063	
macro avg	0.83	0.84	0.83	1063	
weighted avg	0.93	0.92	0.92	1063	
RF:99.97					
	precision	recall	f1-score	support	
0	0.96	1.00	0.98	925	
1	0.97	0.75	0.84	138	
accuracy			0.96	1063	
macro avg	0.97	0.87	0.91	1063	
weighted avg	0.96	0.96	0.96	1063	

MODELLING RESULT

Tahap 2 – Meningkatkan Performa Model

- Pada tahap ini dilakukan pencarian model terbaik menggunakan *Randomized Search CV* dan *Grid Search CV* berdasarkan hasil Tahap 1 dimana model terbaiknya adalah *Random Forest*.

```
RandomForestClassifier  
RandomForestClassifier(bootstrap=False, max_depth=60, min_samples_split=5,  
                        n_estimators=600)
```

```
RF:97.4  
  
              precision    recall  f1-score   support  
  
    0               0.96        1.00        0.98         925  
    1               0.97        0.73        0.83         138  
  
   accuracy                0.96         1063  
  macro avg               0.97        0.86        0.91         1063  
 weighted avg               0.96        0.96        0.96         1063
```

- Dari proses pemodelan yang dilakukan, rekomendasi yang digunakan adalah *Random Forest* menggunakan *max_depth* = 60, *min_samples_split* = 5, dan *n_estimator* = 600 dengan *accuracy* : 0.96 , *precision* : 0.97, dan *recall* : 0.73.

FINAL RESULT

- Berdasarkan pemodelan yang telah dilakukan dengan menggunakan KNN, *Decision Tree*, dan *Random Forest*, maka dapat disimpulkan untuk memprediksi *churn* dengan menggunakan dataset ini model terbaiknya adalah menggunakan *Random Forest*.